

淘宝用户行为漏斗分析 · 项目复盘

一句话：用 1000 万条淘宝用户行为日志，把「逛 → 加购 → 买」这条路上的每一步查清楚，并推翻三条听起来很对、但数据不支持的常识。

一、项目概况

项目	内容
数据来源	Kaggle「User Behavior Data from Taobao」（阿里天池同源）
数据规模	原始 1 亿行（3.67 GB）；分析用样本 1000 万行
覆盖时间	2017-11-25 ~ 2017-12-01（7 天分析窗口）
分析对象	样本 99,020 个用户（9 天建库窗口）；商品 158.8 万件、类目 8,044 个
主要工具	DuckDB + SQL（取数）、Python + Matplotlib（画图）
产出	9 组 SQL、20 张结论图、10 篇分析文档、4 张 Tableau 聚合表
项目定位	通用数据分析能力（漏斗 / 留存 / 分层 / 行为序列）

二、数据说明

原始表只有 5 列，没有表头，逗号分隔：

列	含义
user_id	用户 ID（已脱敏）
item_id	商品 ID
category_id	类目 ID（脱敏编号，没有类目名称）
behavior	行为类型：pv 浏览 / fav 收藏 / cart 加购 / buy 购买
timestamp	事件时间（Unix 秒，已换算北京时间）

四个必须提前知道的处理：

- 按用户抽样，不是按行抽。用 `hash(user_id) % 100 < 10` 抽 10% 的用户、保留他们的全部行为。
按行截取只会抽到最早注册的老用户；按行随机抽会把稀有的购买事件整条抽没。
抽样后四类行为占比与全量的偏差 < 0.06 个百分点。
- 剔除了 0.055% 的异常时间戳（负数、1902 年、2037 年等）。
- 剔除了 12-02 / 12-03 两天——这两天的当日活跃覆盖率从 72~75% 跳到 98.19%，
同一个 10% 抽样不可能差这么多，判定为数据口径不一致（见结论 7）。
由此产生两个窗口：建库窗口 9 天（11-25 ~ 12-03）、分析窗口 7 天（11-25 ~ 12-01）。
- 换算成北京时间（+8 小时）。不换算的话，晚高峰会整体偏移 8 小时。


数据里没有的东西（全项目不能出现）：没有金额、没有订单号、没有商品名和价格。
所以本项目**不做 GMV、不做客单价、不做 ROI**。

三、分析流程（10 步）

步	回答的问题	主要方法	一句话结论
S1	全站长什么样	四类行为占比 + 用户级覆盖	浏览占近九成，天然逛多买少
S2	人丢在哪一步	严格嵌套漏斗 + 人/商品双口径	没有卡点 ；购物车是比价清单
S3	什么时候最想买	小时级三重渗透率对照	加购含金量 10 点最高；顺带查出数据异常
S4	来的人还回不回来	日活留存 + 队列回访	回访率几乎不衰减
S5	买过的人还买吗	两种复购口径对照	一次即走 54.30%；跨天买同一商品仅 1.63%
S6	类目该不该分开定 KPI	卡方 + 效应量 + 分半复现	差 20.6 倍，但 关联很弱
S7	资源该押给谁	按行为量三等分	重度用户拿 68% 流量只产 53% 成交
S8	用户实际怎么走	会话切分 + 一阶转移矩阵	66.37% 会话纯浏览； 加购不是扳机
S9	沉默的购物车值不值得捞	分层 + 截断检验 + 情景测算	一半的人握 84.47% 的机会
S10	所以呢	三条动作建议 + 看板	见第四节结论 6

四、核心结论

结论 1 • 标准漏斗在这份数据上不成立



浏览 98,460 → 加购 66,138（**67.17%**）→ 加购且购买 42,473（**64.22%**）。
两步只差 2.95 个百分点，没有卡点。

⚠ 本文所有数字一律用 7 天口径，这是本文与项目原始图表唯一的差异来源。

项目建库时用的是 9 天窗口（11-25 ~ 12-03），S3 查出 12-02/12-03 异常之后，

从 S3 起整个项目改为 7 天窗口。所以你去翻项目里 S1/S2 的原始图表

（例如 output/charts/s2_funnel.png），看到的是 9 天口径的数：

浏览 98,611 / 加购 74,220 / 成交 53,342，通过率 75.3% 与 71.9%。

那不是算错，是另一个窗口。对外报数一律用本文这套 7 天口径。

这不是好消息，而是说明**数据被筛过**：7 天窗口内有购买行为的用户占 **58.04%**，

而真实电商通常是个位数。所以这批用户是**筛选过的活跃 / 购买倾向人群**。

这条决定了整个项目的讲法：只讲相对结构（哪一步掉得狠、哪群人更容易转化、高峰在几点），
绝不外推绝对水平。

结论 2 • 购物车不是"待付款清单"

口径	数值	问的是
人级	64.25%	加购过的人，有多少最终买了东西
商品级	6.21%	被加进购物车的那件商品，有多少被同一人买走


两个数都对，问的不是一回事。落差本身就是结论：买东西的人多，买"购物车里那件"的人少。

放宽验证（这一条用的是 **9 天窗口口径**，项目里没有对应的 7 天结果集）：

把"买回同款"放宽到"买了同类目任何商品也算"，商品级成交率从 6.47% 只涨到 **16.22%**，

没有跨数量级，排除了"同款换色导致 item_id 变化"的解释。

结论 3 • 加购不是转化的扳机，是意向的标记



统计 604 万次会话内的行为转移：

当前动作	下一步是购买
浏览	1.21%

当前动作	下一步是购买
加购	0.88%
收藏	0.61%

基础概率（三种非购买动作下一步成交的平均值）= **1.17%**。

加购之后下一步就买的概率，比随便抓一个正在浏览的人还低。

加购之后实际在干嘛：接着逛 63.23% / 会话结束 20.12% / 再加购一件 14.83% / 购买 0.88%。


结论 4 • 加购带来的成交，近八成发生在会话结束之后

七天内被买回的 24,155 对加购商品里：

- 当场就买：21.52%
- 会话结束之后才买：78.48%

这意味着拿“加购当天成交率”考核运营，会系统性低估加购的价值——四分之三的效果当天还没发生。
真正该做的是“把加购商品在之后的会话里重新送到他面前”，而不是“在加购那一刻催他下单”。

结论 5 • 三分之二的会话是纯浏览




全部 1,217,569 个会话里，**66.37% 没有任何意向动作**（没加购、没收藏、没购买）。

换会话阈值 15 / 30 / 60 分钟，这个数只从 68.53% 挪到 64.09%（差 4.44 个百分点）——

说明它是数据本身的性质，不是阈值切太碎切出来的。

结论 6 · 沉默的购物车：一半的人握着八成半的机会



指标	数值
加购商品对	389,170
七天内成交	24,155 (6.21%)
沉默 (未成交)	365,015 (93.79%)
D 层 (沉默 ≥ 4 件)	32,942 人 (占 49.51%) 握 84.47% 的沉默件
站内可触达	89.21% (下界)
加购到购买最大的一档	6~24 小时，占 33.08%

动作建议：名单发给 D 层（覆盖面不变、人数减半）；时点从“加购当下”推到“次日上午”；

每提升 1 个点的沉默成交率 = 3,650 件。提升幅度必须靠 A/B 实验验证。

结论 7 · 从“不可能的数字”倒查出两天的数据异常

算留存时得到：队列 11-25 的 D7 回访率 98.54% > D1 的 78.77%。

留存不可能反弹，顺着查下去：


日期	当日活跃覆盖率
11-25 ~ 12-01	稳定在 72% ~ 75%
12-02	98.19%

两步排除：**不是限时活动**（同为周六的两天按小时比值全天平坦，平均 1.30 倍）；

不是拉新（12-02 当天 9.7 万活跃用户里，窗口内第一次出现的只有 2 个人）。

排除完只剩一个解释：这两天口径不同，**剔除**。

结论 8 · 类目差异是真的，但很弱



指标	值	说明
类目转化率极差	20.6 倍 (0.74% ~ 15.24%)	差异是真实的
卡方 p 值	小到打印不出	61 万配对下，p 值没有信息量
Cramér's V	0.1322	弱关联 → 类目不是决定性因素
转化率 95% CI 中位宽度	0.72 个百分点	"显著"的门槛低得没有决策价值
分半复现	Spearman 0.994，Top 10 重合 10/10	该不该按类目定 KPI → 看这个

五、名词与指标解释

名词	一句话解释
口径	一个指标"怎么算"的定义：分子是谁、分母是谁、时间窗口多长。口径错了，后面全错
转化率 / 通过率	做了下一步的人数 ÷ 做了上一步的人数。本项目一律用"人"而不是"次数"

名词	一句话解释
严格嵌套漏斗	下一层的人必须是上一层人的子集。收藏和加购是 并联 关系，不能串成一条链（串了会算出 171.79% 这种超过 100% 的比率）
渗透率	做过某个行为的用户 ÷ 全部用户。关注"有多少人做过"，不看做了几次
留存率 / 回访率	某天第一次出现的人，第 N 天后还有没有活跃。本项目数据没注册时间，所以叫"回访率"而不是"新客留存"
复购	无订单号，用"有购买行为的自然日数 ≥ 2 天"近似。同一天买两次只算 1 次，所以是 保守低估
会话 (session)	把同一用户的行为按时间串成"一次访问"。 数据里没有会话 ID，是本项目自己定义的 ：相邻行为间隔 > 30 分钟算新会话
一阶转移概率	站在某个动作上，下一个动作是什么的概率（如 加购 → 购买 = 0.88%）
基础概率 (基准率)	什么都不看时，随机挑一个动作其下一步成交的概率（本项目 = 1.17%）。有它才能判断"0.88% 算高还是低"
卡方检验	检验两个分类变量是否 相关 。"显著"只说明"不是抽样偶然"， 不说明差异有多大
p 值	差异有多大可能是碰巧造成的。 样本一大必然极小，本身没有决策价值
效应量 (Cramér's V)	差异"有多大"。0~0.2 弱、0.2~0.4 中、0.4 以上强
置信区间	用样本能推出来的真值范围。区间太窄说明"显著"的门槛太低
右删失 / 截断偏差	观察窗口太短，晚期事件来不及发生。 误差方向固定 ，只会制造"假的好消息"
分半复现	把数据切两半分别算，看结论是否一致。本项目用 Spearman 秩相关衡量排序一致性
选择效应	被比较的两组人 本来就不是同一批人 （如加购的人决策周期天然更长），所以不能反推因果
描述性 vs 因果	描述性=发生了什么；因果=为什么发生、如果干预会怎样。本项目 只做描述性
上界 / 下界	因为口径不完美，只能说"至少/至多是多少"。如站内可触达 89.21% 是 下界

六、面试问答

Q1：这个项目做了什么？（30 秒）

用 1000 万条淘宝行为日志做交易漏斗分析。最有价值的部分不是查到了什么，而是**三条听起来很对的常识被数据推翻了**：重度用户拿走 68% 的流量却只产 53% 的成交；加购之后下一步成交的概率只有 0.88%，比随机一个非购买动作的平均 1.17% 还低；晚上加购最多，但那批人的成交率最低。

Q2：为什么说"没有卡点"？

浏览到加购 67.17%、加购到购买 64.22%，**两步只差 2.95 个百分点**。漏斗分析的用途是回答"资源该往哪一步投"，两步掉得一样狠就没有答案。**更根本的是：不是"漏斗正常"，是"漏斗在这份数据上不成立"**——75% 的浏览到加购率在真实电商是个位数，原因和 58% 的购买渗透率是同一件事：这批用户本来就是想买的人。

Q3：58% 的人有购买行为，数据是不是有问题？

对，这正说明它不是全站流量。真实电商的购买用户占比是个位数。**这件事我选择主动讲出来**，因为它决定了我的结论只能讲相对结构、不能外推绝对水平。被面试官先点破就是减分项。

Q4: 加购到购买 64%，那不就该催单吗？

64.25% 是**人的口径**（加购过的人有多少买了东西），**商品口径**只有 6.21%（被加购的那件商品被同一人买走）。落差本身就是结论：买东西的人多，买“购物车里那件”的人少。所以“针对购物车商品催单”这个方向是错的。

Q5: 6.21% 是不是因为窗口只有 7 天？

做过三口径截断检验：按加购日拆开，**一小时内成交率 1.45~1.84%（平）、一天内 3.98~4.67%（平）**，只有“窗口内成交率”从 7.85% 单调掉到 1.63%。**短口径平、只有长口径掉，说明掉的是观察时间，不是转化能力**。干净参照是 11-25 批次的 7.85%。

Q6: p 值这么小，你怎么说类目不是关键？

p 值只回答“差异会不会是抽样偶然”。61 万配对下，**0.1 个百分点的差异都不可能是偶然**，所以 p 值必然极小、没有信息量。真正的证据是**效应量 Cramér's V = 0.1322（弱）**和置信区间中位宽度只有 0.72 个百分点。该不该按类目定 KPI，我用**分半复现**来判：Spearman 0.994、Top 10 重合 10/10。

Q7: 样本怎么抽的？为什么不直接截前 1000 万行？

全量 1 亿行，按 `hash(user_id) % 100 < 10` **抽 10% 的用户**并保留他们的全部行为。截前 1000 万行的话，文件按 user_id 聚块排（实测前 30 万行只有 2,953 个用户），**等于只抽了最早注册的老用户**；按行随机抽，购买只占 2%，**很容易被整条抽没**，转化率会被系统性低估。抽完验证行为占比偏差 < 0.06 个百分点。

Q8: 加购之后下一步成交概率这么低，说明什么？

说明“**下一步**”这个框架本身不适用。加购带来的成交 78.48% 发生在会话结束之后，当场成交只有 21.52%。**加购不是扳机，是意向的标记**——它标记“这个人在认真考虑”，不标记“这单快成了”。

Q9: 这个项目最大的不足？

三条：**没有金额**，所以结论停在“件数”而不是“钱”，我给不出 GMV 和 ROI；**窗口只有 7 天**，“沉默”是 7 天内的沉默，真实比例一定更低，但测不出低多少；**全是描述性分析，没有因果**——“加购的人沉默率高”不等于“加购导致沉默”，加购的人本来就和没加购的人不是一批人，这是选择效应。

Q10: 如果数据里有金额，结论会怎么变？

会从"件数"升级到 GMV 拆解和 ROI 排序：可以把 93.79% 的沉默加购按金额排序，算出优先捞哪一批的收益最大，也能把触达成本和券成本放进来净收益。但这份数据从原理上做不到，所以我停在件数，把验证交给 A/B。

七、已知局限

1. **没有金额字段** → 不做 GMV、客单价、ROI；测算只用件数和人数。
2. **用户是筛选过的活跃人群**（58% 有购买行为）→ 绝对水平不可外推。
3. **窗口只有 7 天** → 月级周期看不到；所有跨期转化率都做了截断检验，但只能声明方向。
4. **没有订单号** → 复购用自然日近似，是保守低估。
5. **没有注册时间** → 留存只能用"窗口内第一次出现"代理，一律说"回访率"。
6. **会话阈值是自定的** → 规模类指标（会话数、人均会话数）是阈值相关的，不能当固定事实。
7. **同款不同 SKU 无法识别** → 已用"同类目"口径做放宽验证，结论不变。
8. **全是描述性分析** → 不做因果推断，也不给"干预后能提升多少"的真实数值。